ANÁLISIS PROFUNDO DE RESULTADOS

Química de productos naturales y aprendizaje automático

Fecha del informe: 15 de octubre de 2026

Resultados: 15 de octubre de 2026; corrida registrada entre 12:35:45 y 12:36:48.

Alcance: 49 resúmenes de modelos y cuatro datasets fuente; tareas no supervisadas compatibles.

Resumen ejecutivo

Los resultados permiten explorar perfiles y priorizar revisiones, pero todavía no justifican conclusiones biológicas ni la elección de un único modelo ganador. En patrones químicos, los grupos se asocian fuertemente con batch y especie; la cobertura química es baja para muchas muestras, y batch y especie están confundidos. En calidad por muestra, numerosas filas repiten las mismas métricas por batch. Puntajes internos altos no demuestran generalización ni validez biológica.

- Clustering químico: silhouette K-Means 0,530 y DBSCAN 0,751; pero DBSCAN tiene NMI con batch 0,962 y 96,9 % de muestras externas fuera del soporte estimado.
- Cobertura: 81,6 % de registros sin clase asignada. En calidad por muestra, la mediana de cobertura es 6,25 %; 52,5 % de perfiles usados tiene cobertura menor al 30 %.
- Calidad: los cuatro detectores coinciden en cinco batches candidatos a revisión, no confirmados como errores.
- Markov: precisión 28,1 % frente a 0,06 % del baseline de orden cero en un holdout; señal prometedora que debe repetirse por batch.

1. Alcance y fechas

La copia incluye 49 resúmenes JSON, todos con el archivo fuente identificado. Los informes globales se generaron el 15/10/2026 a las 12:36:48; las marcas de tiempo de modelos van de 12:35:45 a 12:36:48. Se guardaron 15 resultados de clustering, 16 de reducción, 16 de anomalías, uno de asociación y uno de Markov.

Patrones químicos alimenta clustering, reducción, anomalías, asociación y Markov. Los informes de calidad por batch y muestra y los metabolitos sin clase alimentan clustering, reducción y anomalías. No hay etiquetas de referencia que permitan medir validez biológica.

2. Patrones químicos: cobertura y unidad de análisis

04_Dataset_Patrones_Quimicos.csv contiene 965.653 registros y 974 muestras. El clustering trabaja sobre 866 perfiles de muestra con 337 features, no sobre cada pico. Otras 108 muestras carecen de perfil positivo utilizable.

- 788.091 registros (aprox. 81,6 %) no tienen clase química asignada.
- Por muestra: 108 sin clasificación, 726 con cobertura parcial y 140 completa.
- Cobertura media 34,5 %, pero mediana 6,25 %: la media no representa a la muestra típica.
- De los 866 perfiles usados, 455 tienen cobertura menor al 30 % (52,5 %) y 490 menor al 50 % (56,6 %). La cobertura química utilizable mediana es 15,4 %.

Los ceros pueden significar clase no detectada o no clasificada; no prueban ausencia química. Las firmas por grupo pueden reflejar cobertura además de química.

3. Clustering químico y generalización

K-Means obtiene 15 grupos, silhouette 0,530 y estabilidad ARI 0,899. Su asociación con batch es alta (NMI 0,853; ARI 0,672) y con especie también (NMI 0,781; ARI 0,505). Agglomerative tiene silhouette 0,533. Son diagnósticos internos, no validación independiente.

DBSCAN alcanza silhouette 0,751 con 44 clusters y 2,31 % de ruido, pero NMI con batch 0,962 y ARI 0,923. En batches no vistos, 96,9 % de muestras queda fuera del soporte estimado. No es un ganador por tener silhouette más alto.

En batches externos quedan fuera del soporte 72,7 % de muestras para K-Means, 70,7 % para Agglomerative y 77,1 % para Gaussian Mixture. Para algunos modelos se usa centroide como diagnóstico; no equivale a predicción nativa.

El diseño está confundido: 86,1 % de batches contiene una sola especie y 87,8 % de especies aparece en un solo batch. Sin especies compartidas entre lotes no se puede atribuir con confianza un cluster a biología y no al proceso experimental.

El grupo K-Means más numeroso (107 muestras) tiene cobertura media de 9,8 % y mediana de 2,4 %. Interpretar su firma como marcador biológico sin controlar cobertura sería prematuro.

4. Calidad por batch y por muestra

Calidad por batch

El informe tiene 44 filas: 39 batches con muestras y cinco sin registros identificados. Estos cinco representan falta de información, no calidad química cero. La cobertura mediana es 23,38 % y la media 34,80 %. Las features incluyen conteos absolutos y derivados, por lo que los modelos pueden agrupar por tamaño de batch.

Los cuatro detectores coinciden en batches 9, 10, 15, 19 y 23. Sus coberturas son 0,79 %, 1,12 %, 2,36 %, 12,25 % y 60,82 %. Algunos tienen numerosas alturas faltantes. Revisarlos en los datos originales es prioritario, pero la coincidencia no confirma errores.

Calidad por muestra

Hay 974 muestras, pero 27 de 39 batches tienen exactamente el mismo vector de métricas en todas sus muestras y 35 de 39 tienen como máximo dos perfiles métricos. Así, el modelo puede estar separando batches, no detectando anomalías individuales.

Los cuatro detectores coinciden en 26 muestras: IDs 979–995 del batch 19 e IDs 1402–1410 del batch 44. Sus métricas son repetidas por batch. Sus coberturas son 12,25 % y 82,76 %. Verificar réplicas, agregación y metadatos antes de etiquetarlas como anomalías individuales.

5. Metabolitos sin clase química

Hay 22.272 metabolitos; 5.841 no tienen fórmula molecular. De las fórmulas presentes, 95,3 % pasan validación sintáctica. Solo dos filas sugieren coincidencia exacta, y ambas requieren revisión: no son etiquetas químicas verificadas.

El clustering describe fórmula, longitud, validez, frecuencia y número de batches; no descubre clases conocidas. Agglomerative tiene silhouette 0,969, pero tamaños 1, 1 y 4.998: dos singleton y un grupo dominante. K-Means y Gaussian Mixture también generan grupos desiguales. Algunos modelos cuadráticos usan 5.000 de 22.272 filas.

Estos resultados describen similitud de descriptores y recurrencia; cualquier propuesta química requiere curación experta.

6. Asociación y Markov

Reglas de asociación

Apriori produjo 6.697 reglas con soporte mínimo 0,15 y confianza mínima 0,70; se guardaron 200 para inspección. Una de las reglas con mayor lift es “Heterocyclic compounds + Ketone compounds → Other Flavonoids”: soporte 15,5 %, confianza 93,7 % y lift 5,24. Son coocurrencias descriptivas, no causalidad; batch y cobertura pueden influir.

Cadenas de Markov

El holdout por batch evalúa 14.937 transiciones; 98,8 % está en el vocabulario entrenado. Precisión del siguiente estado 28,1 %, frente a 0,06 % del baseline de orden cero. Log-verosimilitud media −3,209 frente a −3,255: mejora más modesta. Una partición y transiciones correlacionadas no prueban reproducibilidad; repetir con varios holdouts por batch.

7. Reducción y anomalías

Trustworthiness (aprox. 0,92–1,00) mide conservación de vecindarios, no clasificación ni generalización. En calidad por batch y muestra, PCA conserva 100 % porque mantiene las cinco o siete dimensiones disponibles: no reduce realmente. En patrones, 10 componentes conservan 80,1 % de varianza; en metabolitos, 67,2 %.

One-Class SVM marca aprox. 49,3 % de perfiles químicos, 50 % de batches y 47,5 % de muestras; el volumen es excesivo para tratarlo como fallos sin calibración. En patrones, la silhouette normal/anomalía está cerca de cero, indicando poca separación geométrica. Algunos detectores trabajan con submuestras; no extrapolar sus conteos al total.

8. Prioridades

- Definir cobertura mínima y sensibilidad antes de agrupar; reportar medianas, distribuciones y exclusiones.
- Revisar batches sin registros y contrastar conteos con archivos crudos; distinguir falta de datos de mala calidad.
- Repetir validación dejando batches completos fuera. No llamar validación externa al puntaje de ajuste usado para elegir parámetros.
- Reducir confusión batch-especie mediante un diseño con especies compartidas entre batches; evitar atribuciones biológicas hasta lograrlo.
- Verificar réplicas y variación real dentro de batch antes de llamar anomalías a muestras individuales.
- Presentar K-Means y DBSCAN como herramientas exploratorias; mostrar tamaños, cobertura, batch/especie y firmas químicas.
- Calibrar umbrales de anomalía con criterios revisados por expertos. Usar consenso para priorizar inspección, no para confirmar errores.
- Repetir Markov en varios holdouts por batch y reportar baseline, cobertura del vocabulario y cantidad de grupos.
- Corregir unidades: `muestras_cobertura_menor_10_pct`, `_30_pct`, `_50_pct` son conteos 387, 455, 490, no porcentajes. Equivalen a 44,7 %, 52,5 % y 56,6 % de 866 perfiles.

Conclusión

Los resultados sirven para priorizar auditorías de cobertura, lotes y muestras, y formular hipótesis de coocurrencia. La principal limitación no es elegir otro algoritmo, sino la cobertura química incompleta y la confusión batch-especie. El siguiente paso de mayor valor es auditar lotes extremos, separar ausencia de información de ausencia química y repetir evaluaciones con batches externos y cobertura suficiente. Hasta entonces, clusters y anomalías son exploratorios, no conclusiones biológicas.

Contenido de la entrega

- 03_Resultados/: copia completa de resultados y reportes del 15/10/2026.
- Datasets_Entrenamiento/: copias de los cuatro CSV 04_ usados.
- Este PDF: análisis referido a la corrida registrada el 15/10/2026.