Resumen ejecutivo

Aprendizaje no supervisado sobre patrones quimicos

14	13	1
modelos registrados	completados	fallido (DBSCAN)

Lectura principal

La ejecucion produjo resultados exploratorios utiles para priorizar analisis, pero no evidencia concluyente de grupos quimicos biologicamente diferenciados. De los 13 modelos completados, 12 incluyen alertas de interpretacion.

Las metricas pertenecen a tareas distintas y no deben compararse directamente. En aprendizaje no supervisado, la ausencia de una variable objetivo Y es esperada, no un dato faltante.

Hallazgos destacados

- Clustering: la mejor silhouette observada fue 0,174 (Agglomerative); los tres metodos evaluables quedaron por debajo de 0,25, senal de separacion interna debil.
- Markov: precision de 24,21 % para predecir el siguiente estado, frente a 0,13 % del baseline de orden cero; la cobertura del vocabulario fue 91,37 %.
- Anomalias: los metodos discrepan ampliamente (0 % a 49,06 % de las muestras), por lo que sus senalamientos requieren revision y no confirman errores.
- Asociacion: Apriori obtuvo 32.214 reglas y lift medio 2,09; las reglas describen coocurrencias, no causalidad.

Resultados por tarea

Clustering | 4 registrados: 3 completados y 1 fallido

Agglomerative: 6 grupos, silhouette 0,174 y estabilidad ARI media 0,823. K-means: 5 grupos, silhouette 0,157 y ARI 0,698. Gaussian Mixture: 2 grupos, silhouette 0,114 y ARI 0,172. Los tres presentan separacion debil; las cifras de estabilidad son descriptivas, no validacion biologica.

DBSCAN no produjo un agrupamiento evaluable en las 12 configuraciones intentadas. El fallo indica que no se encontro densidad suficiente con esa busqueda, no necesariamente un problema de integridad de los datos.

Deteccion de anomalias | 4 modelos completados con alertas

Porcentaje marcado: Elliptic Envelope 11,32 %; Isolation Forest 9,43 %; Local Outlier Factor 0 %; One-Class SVM 49,06 %. Esta variacion refleja sensibilidad a algoritmo y parametros. Elliptic Envelope tambien reporto covarianza potencialmente singular con 812 caracteristicas.

Reduccion de dimensionalidad | 4 modelos completados

Trustworthiness: Isomap 0,985; Kernel PCA 0,970; PCA 0,970; t-SNE 0,928. PCA retuvo 72,48 % de varianza acumulada. La conservacion de vecindarios evalua estructura local, no confirma clusters ni calidad predictiva.

Reglas de asociacion | Apriori

Se registraron 32.214 reglas con soporte minimo 0,15, confianza minima 0,70 y lift medio 2,09. El diagnostico legible contiene como maximo 200 reglas. La mediana fue de 12 muestras clasificadas por perfil y el minimo, 3; la base de soporte es limitada.

Interpretacion y siguientes pasos

Cadena de Markov | modelo de orden 1

Se modelaron 1.079 secuencias de 704 muestras, en 4 modos de ionizacion y 29 lotes. En 180.363 transiciones evaluadas, la precision del siguiente estado fue 24,21 %, una mejora de 24,07 puntos porcentuales frente al baseline de orden cero (0,13 %). La cobertura de vocabulario fue 91,37 %; quedaron transiciones fuera de los estados vistos en entrenamiento.

La comparacion agrupada por lotes aporta una referencia mas exigente que el azar uniforme, pero la transferencia a nuevos lotes y muestras debe comprobarse en validacion independiente.

Limitaciones relevantes

- Los modelos de clustering, anomalias, reduccion y asociacion trabajaron con 53 filas y 812 caracteristicas; esta relacion favorece inestabilidad y sobreinterpretacion.
- Una muestra marcada como anomala no es necesariamente un error experimental; debe verificarse frente a datos originales, calidad instrumental y metadatos.
- Los ceros en perfiles quimicos pueden indicar no deteccion o falta de clasificacion; no demuestran ausencia del compuesto.
- Las asociaciones entre lote y grupos, si aparecen en diagnosticos, pueden reflejar condiciones experimentales y no diferencias biologicas.

Prioridades recomendadas

- Ampliar el numero de muestras biologicas y mejorar la cobertura de clasificacion quimica antes de concluir sobre especies o grupos.
- Validar clustering y anomalías con conocimiento botánico, controles de calidad y lotes externos; revisar los diagnosticos por muestra.
- Conservar Markov como resultado prometedor, pero repetir la prueba en lotes independientes y reportar cobertura junto con precision.
- Interpretar las reglas como hipotesis para seguimiento experimental; no inferir relaciones causales a partir del lift.