Informe final de análisis

Inteligencia Artificial para descubrir patrones químicos en orquídeas y plantas medicinales

Consolida y profundiza los resultados de **00_Informes**: 15-oct, 16-oct, 21-oct y 22-oct de 2026. Escrito en lenguaje sencillo; los términos técnicos se explican la primera vez que aparecen.

52	57	1 773	5,8 M	25,6 %	18
artículos con datos	lotes (batches)	muestras	señales químicas	con metabolito identificado	experimentos de IA

La respuesta corta. La IA **sí aprende química real de los compuestos**: a partir de la fórmula molecular adivina la familia química de un metabolito (superclase) unas 7 veces mejor que el azar, y anticipa en qué modo se detecta en el espectrómetro. En cambio, **todavía no puede reconocer qué planta es** (especie, género, órgano) a partir de su perfil químico cuando se le muestra un estudio nuevo: lo que mejor "reconoce" es **el laboratorio y el equipo** con que se midió. Las orquídeas (solo 2 estudios: *Gastrodia elata* y *Dendrobium officinale*) no se distinguen todavía; la pista más prometedora son unos estilbenos que comparten ambas.

Contenido. 1. Qué se hizo y cómo leer este informe · 2. Evolución de los informes (15 → 22 oct) · 3. Los datos · 4. Resultados de los 18 experimentos · 5. Patrones químicos y orquídeas · 6. Conclusiones · 7. Posibles errores · 8. Cómo mejorarlo

1. Qué se hizo y cómo leer este informe

El proyecto reúne datos de **metabolómica** (el "inventario químico" de una planta medido con cromatografía + espectrometría de masas, LC/GC-MS) de 52 artículos científicos, y entrena modelos de IA para contestar preguntas como: *¿con el perfil químico puedo saber de qué familia es la planta?* o *¿con la fórmula de un compuesto puedo saber qué tipo de molécula es?*

Para entender los números hay que conocer cuatro ideas:

- **Exactitud balanceada (BA)**: porcentaje de aciertos dando el mismo peso a cada categoría. Va de 0 a 1. Si hay 5 categorías, adivinar al azar da ≈ 0,20; por eso un 0,35 puede ser bueno y un 0,50 puede ser malo según el caso.
- **Precisión promedio (AP)**: equivalente para problemas con varias etiquetas a la vez (p. ej. actividades biológicas).
- **Línea base y control de plataforma**: la línea base es "adivinar con la categoría más común". El control de plataforma es el mismo modelo pero **sin química**, solo con datos del equipo (columna, modo, número de señales). Si el control rinde igual que el modelo, el modelo no está usando química: está reconociendo el laboratorio.
- **Validación agrupada por artículo**: se entrena con unos artículos y se evalúa con **artículos que el modelo nunca vio**. Es la prueba honesta. La validación "sin agrupar" mezcla muestras del mismo estudio en entrenamiento y prueba, y da números inflados (casi siempre ≈ 1,0).

La **ganancia** es la cifra clave: *valor del modelo − la mejor referencia sin química*. Con ella el sistema asigna un veredicto: **señal robusta** (ganancia ≥ 0,15 y p < 0,05), **señal débil** (0,05–0,15), **confundido con plataforma**, **sin señal**, **evidencia insuficiente** (menos de 10 estudios independientes) o **no viable**. El valor **p** sale de una *prueba de permutación*: se barajan las etiquetas muchas veces y se mira si el modelo real supera a los barajados.

2. Evolución de los informes: del 15 al 22 de octubre

Las cuatro carpetas no son cuatro copias del mismo análisis; muestran cómo el proyecto **maduró** de una exploración sin respuesta conocida a un sistema de experimentos con controles.

Fecha	Qué contiene	Hallazgo principal	Lectura
15-oct	49 modelos no supervisados (clustering, reducción, anomalías, reglas, Markov) sobre 4 datasets; PDF de análisis	Silhouette alta (DBSCAN 0,75; K-Means 0,53), pero los grupos coinciden con el lote (NMI 0,96). 81,6 % de registros sin clase química.	Los grupos encontrados eran **lotes**, no biología.
16-oct	Copia de la base (catálogos + DataSet.csv) y 14 modelos no supervisados	Silhouette baja (máx. 0,174); DBSCAN falla; Markov 24,2 % vs 0,13 % de base. Solo 53 filas × 812 variables.	Al corregir la unidad de análisis, la "estructura" desaparece.
21-oct	Auditoría completa de datos, 18 experimentos supervisados (M01–M18), documentación, gráficas	Se introducen validación por artículo, control de plataforma y veredictos. La química del compuesto sí se aprende.	Primer análisis **riguroso**.
22-oct	Resumen ejecutivo actualizado, gráfica global y caché del dataset	Mejoras con CatBoost en M08, M09, M10, M11; M16 pasa a p = 0,032. Faltan M17 y M18 en la tabla.	Versión más reciente; base de este informe.

Lección del 15 y 16 de octubre. Que un algoritmo de agrupamiento obtenga un puntaje alto no significa que haya descubierto algo biológico. El 86 % de los lotes tenía una sola especie y el 88 % de las especies estaba en un solo lote, así que "agrupar por química" era casi lo mismo que "agrupar por lote". Este aprendizaje es el que justificó el rediseño del 21 de octubre.

Cambios entre la corrida del 21 y la del 22 de octubre (mismos datos, mejores modelos):

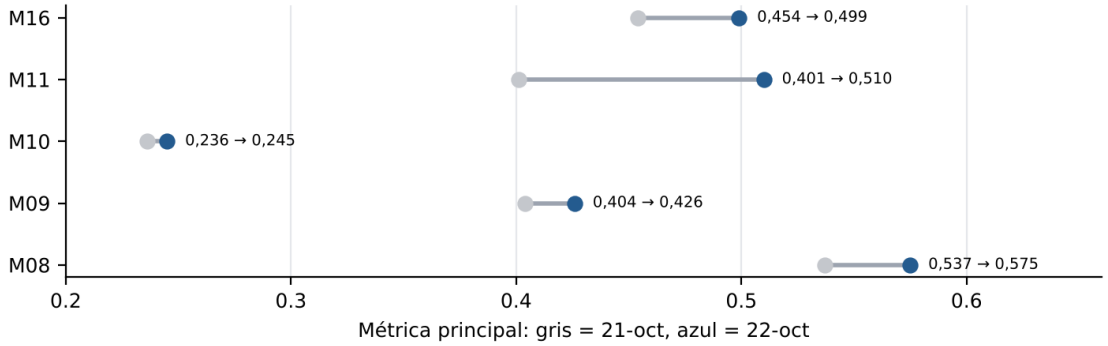


Figura 1. La mejora más grande es M11 (columna cromatográfica, +0,11). Ojo: eso significa que el sistema reconoce mejor el equipo, lo cual no es una buena noticia biológica (ver sección 4).

3. Los datos: qué hay y qué falta

La auditoría del 21-oct revisó 24 archivos. La integridad es **excelente**: 0 claves huérfanas y la jerarquía especie → género → familia es coherente. El problema no es de errores de captura sino de **diseño** de los datos.

Elemento	Cantidad	Explicación sencilla
Filas de Dataset.csv	6 116 075	Cada fila = una señal química en una muestra. 317 797 filas están repetidas por la unión con actividades.
Observaciones químicas reales	5 798 278	5,12 M son de muestras biológicas (sin controles QC ni blancos).
Con metabolito identificado	25,6 %	3 de cada 4 señales son “desconocidas” (nivel IV) y no entran en los perfiles.
Metabolitos distintos	45 842	Identificados con nivel de confianza I–III.
Especies / orquídeas	71 / 2	Solo *Gastrodia elata* y *Dendrobium officinale* son Orchidaceae.
Actividades biológicas	972	81 % son citas de literatura, no ensayos sobre las muestras.

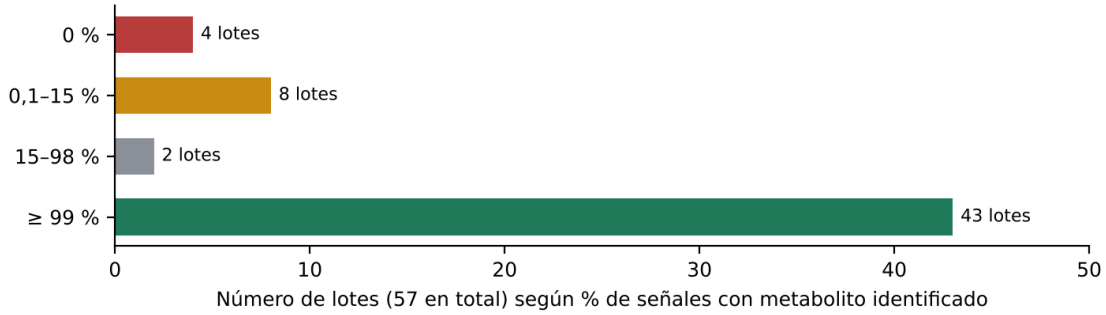


Figura 2. Calidad de anotación por lote. 4 lotes no tienen ningún metabolito identificado y 8 tienen menos del 15 %: esos lotes casi no aportan a los modelos de perfil.

El problema central: todo está mezclado

Cada artículo estudia **una especie**, con **su propio equipo**, **su propia columna** y **su propia biblioteca** de identificación. Solo 2 especies y 3 géneros aparecen en más de un artículo. Es como intentar saber si una persona es de Bogotá o de Lima escuchándola, cuando cada ciudad fue grabada con un micrófono distinto: el modelo puede aprender a distinguir los micrófonos, no los acentos. A esto se le llama **confusión** (en inglés, *confounding*).

4. Resultados de los 18 experimentos

Tabla completa de la corrida más reciente (22-oct). M17 y M18 provienen del 21-oct porque no aparecen en el resumen del 22. Verde = robusta, ámbar = débil, morado = confundido con plataforma, rojo = sin señal, gris = insuficiente / no viable.

Exp.	Pregunta	Métrica	Modelo	Base	Control	Ingenua	p	Veredicto
M01	Modo de ionización (ESI+/ESI−)	BA	0,686	0,503	—	0,702	0,048	Señal robusta
M02	Filo	-	—	—	—	—	—	No viable
M03	Clase taxonómica	BA	0,486	0,521	0,389	1,000	0,806	Sin señal
M04	Orden (9 clases)	BA	0,253	0,116	0,189	1,000	0,032	Señal débil
M05	Familia (9 clases)	BA	0,263	0,111	0,074	1,000	0,032	Señal robusta
M06	Género (3 clases)	BA	0,495	0,333	0,167	1,000	0,032	Evidencia insuficiente
M07	Especie (2 clases)	BA	0,714	0,394	0,000	1,000	0,032	Evidencia insuficiente
M08	Superclase química desde fórmula	BA	0,575	0,078	—	0,589	0,048	Señal robusta
M09	Clase química desde fórmula	BA	0,426	0,025	—	0,447	0,048	Señal robusta
M10	Aducto (15 clases)	BA	0,245	0,067	0,137	0,335	0,048	Señal débil
M11	Columna cromatográfica	BA	0,510	0,200	0,136	1,000	0,032	Señal robusta
M12	Tipo de muestra	BA	0,327	0,333	0,287	0,998	0,710	Sin señal
M13	Parte de la planta	BA	0,141	0,111	0,086	0,886	0,065	Sin señal
M14	Tipo de cultivo	BA	0,354	0,200	0,142	0,961	0,032	Señal robusta
M15	Método de extracción	BA	0,515	0,167	0,543	1,000	0,032	Confundido con plataforma
M16	Presencia de 60 metabolitos	AP	0,499	0,364	0,591	0,881	0,032	Confundido con plataforma
M17	Actividades de la especie*	AP	0,416	0,300	0,437	0,700	0,020	Confundido con plataforma
M17b	Actividades del metabolito	AP	0,436	0,292	—	0,499	0,039	Señal débil

** M17 corresponde a la corrida del 21-oct. M18 (patrones químicos) es descriptivo y se trata en la sección 5. BA = exactitud balanceada; AP = precisión promedio; Base = adivinar la clase más común; Control = solo datos del equipo; Ingenua = validación sin agrupar por artículo.*

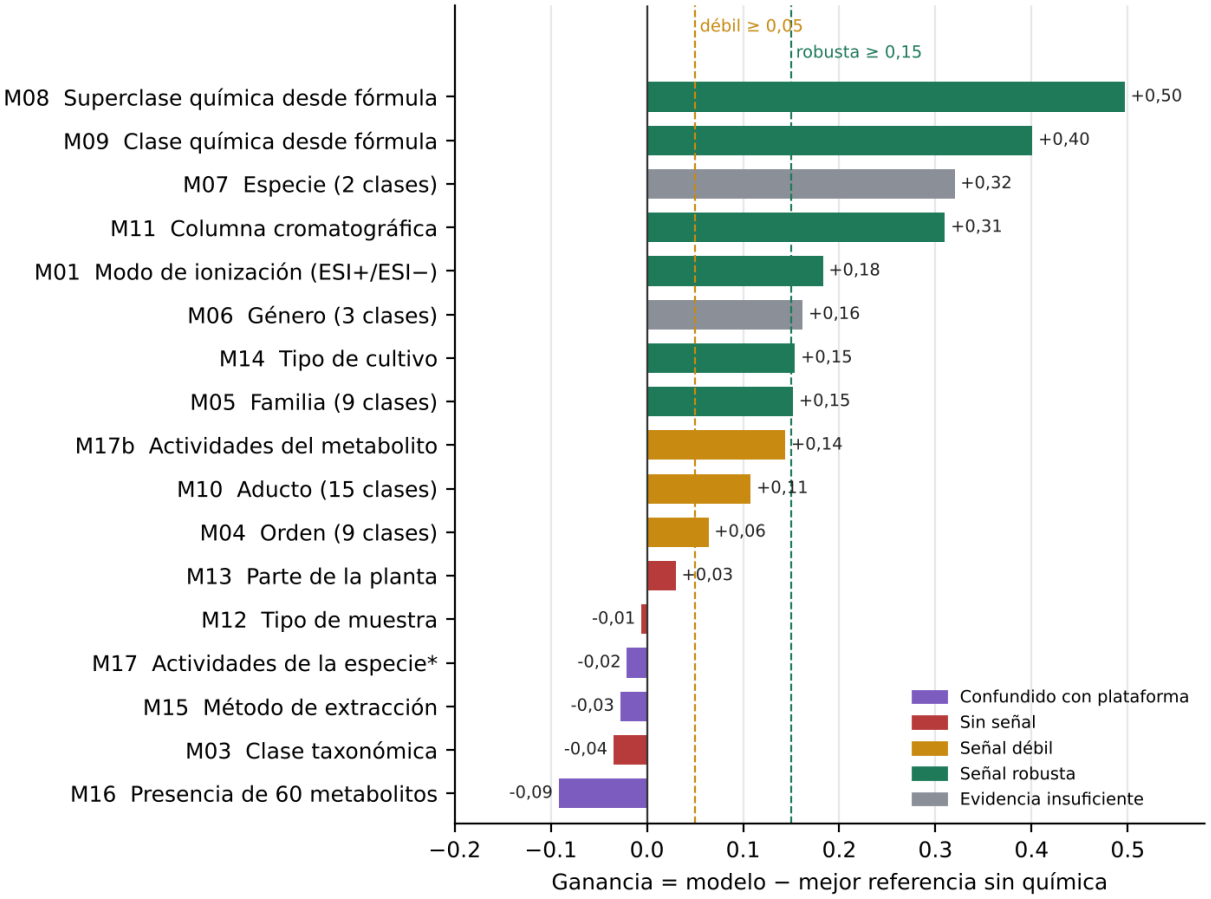


Figura 3. Ganancia real de cada experimento. Solo lo que está a la derecha de la línea verde discontinua es una señal clara. Las barras a la izquierda de 0 significan que el modelo es peor que la referencia sin química.

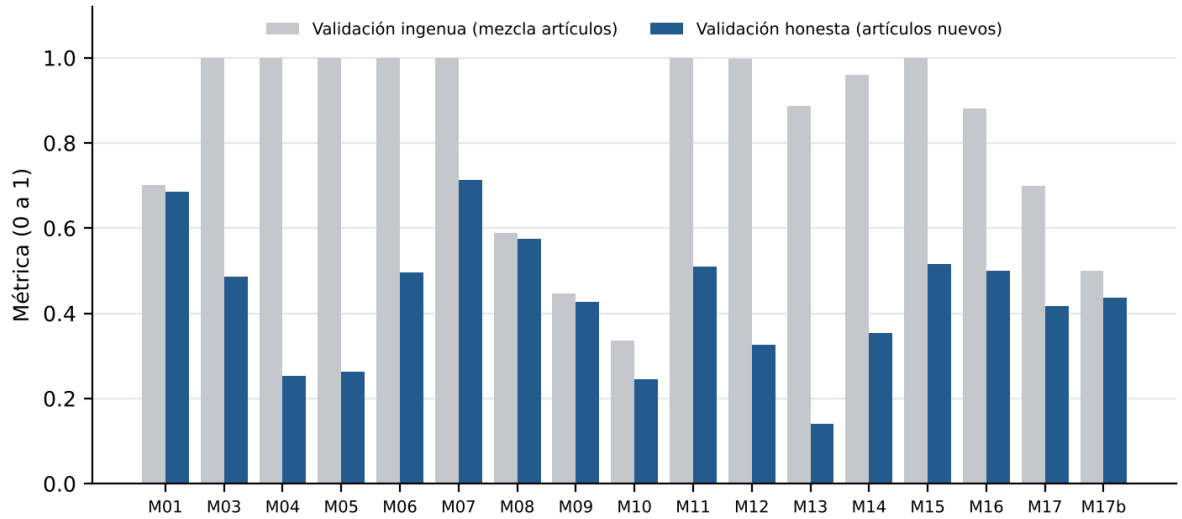


Figura 4. Barra gris = lo que se reportaría si se mezclan muestras del mismo estudio (casi 1,0, engañoso). Barra azul = rendimiento real en estudios nuevos. La distancia entre ambas es el "efecto estudio".

4.1 Lo que funciona: química del compuesto

- **M08 – Superclase desde la fórmula** (0,575 vs 0,078 de azar, 13 clases): conociendo solo cuántos C, H, O, N… tiene una molécula, el modelo acierta su gran familia química más de la mitad de las veces, y lo hace en **fórmulas que nunca vio**. Las variables más útiles (O/C, H/C, heteroátomos, insaturaciones) son las del clásico diagrama de Van Krevelen: el modelo aprendió química de verdad.
- **M09 – Clase desde la fórmula** (0,426 vs 0,025, 40 clases): 17 veces mejor que el azar. El techo se debe a los **isómeros**: moléculas con la misma fórmula pero distinta estructura y clase.

- **M01 – Modo de ionización** (0,686 vs 0,503): la fórmula anticipa si un compuesto se verá en modo positivo o negativo. Coherente: los compuestos oxigenados y ácidos ionizan en negativo.
- **M10 – Aducto** (señal débil) y **M17b – Actividad del metabolito** (señal débil, sobre todo antimicrobiano y antioxidante): hay algo, pero pequeño y con pocos datos (93 metabolitos).

4.2 Lo que no funciona todavía: identificar la planta

- **M05 – Familia** sale “robusta” (0,263 vs 0,111), pero casi todo el acierto viene de **Rubiaceae** (recall 0,89). **Orchidaceae tiene recall 0**: ninguna orquídea de un estudio nuevo fue reconocida.
- **M03 clase taxonómica, M12 tipo de muestra, M13 parte de la planta**: sin señal; no superan a la referencia.
- **M06 género y M07 especie** muestran números altos (0,50 y 0,71) pero con solo 8 y 4 artículos: es ruido, no conclusión.
- **M11 columna cromatográfica** “robusta” (0,51): el perfil químico delata qué columna se usó. Esto **no es un éxito** biológico; es la medida directa de cuánto pesa el equipo en los datos.
- **M15 extracción, M16 presencia de metabolitos, M17 actividades por especie**: el control sin química rinde igual o mejor. Lo que se detecta depende de la biblioteca del laboratorio.
- **M14 tipo de cultivo** (0,354 vs 0,200): supera las referencias, pero el cultivo casi no varía dentro de un artículo, así que puede reflejar otras características del estudio. Tratar como hipótesis.

5. Patrones químicos (M18) y orquídeas

M18 no predice: describe. Usa 111 unidades (especie × artículo × parte) de 51 artículos.

- **¿Qué explica la variación química?** El artículo explica prácticamente todo (R^2 ajustado 0,99). La familia aporta una señal pequeña pero significativa (R^2 0,79 frente a 0,67 esperado al azar, $p = 0,026$). Dentro de un mismo estudio, la parte de la planta, el cultivo y la especie explican ≤ 2 %.
- **Compuestos que aparecen juntos** (con un control que corrige por el tamaño de la biblioteca): 160 de 1 770 pares. Los más fuertes tienen sentido químico: ácidos orgánicos + acilos grasos, glicerofosfolípidos + esteroides, flavonas + flavanonas. Apuntan a **rutas biosintéticas** reales (lípidos de membrana, ruta de flavonoides).
- **Reglas taxón → química** respaldadas por ≥ 2 artículos: Solanaceae → aminas (lift 4,6; 4 artículos), Lamiaceae → aminas/alcaloides de triptófano, Moraceae → fenilpropanoides C6-C3 (lift 4,8).
- **Agrupamiento**: 3 grupos estables (silhouette 0,50), pero no coinciden con la taxonomía (AMI 0,13).
- **Química ↔ actividad**: ninguna superclase queda asociada a una actividad tras corregir por comparaciones múltiples.

Orquídeas. *Gastrodia elata* y *Dendrobium officinale* comparten 73 metabolitos. Cinco de ellos son raros en los otros 49 artículos (≤ 10 %): **dihidroresveratrol, isorhapontigenina, pterostilbeno** (estilbenos), **equol** y **grosamida**. Su perfil tiene algo menos de fenilpropanoides/policétidos (−8 puntos) y algo más de lípidos, ácidos orgánicos y bencenoides. Son **candidatos**: con 2 estudios medidos en equipos distintos no se puede separar la planta del método. Los estilbenos son conocidos en orquídeas, lo que hace la pista plausible y digna de verificación.

6. Conclusiones en lenguaje sencillo

- **1. La herramienta útil hoy** es la que trabaja con compuestos: clasificar fórmulas sin clase (el 78 % de las observaciones no tiene clase química asignada) y anticipar modo de detección.
- **2. No se puede afirmar** que el perfil químico identifique la especie, el órgano o el tipo de muestra entre estudios. Cualquier exactitud cercana a 1 publicada sin agrupar por artículo estaría midiendo el estudio.
- **3. Los patrones con respaldo** son coocurrencias de clases biosintéticamente relacionadas y unas pocas reglas taxón → química.
- **4. Las orquídeas** no se distinguen aún; los estilbenos compartidos son la pista principal.
- **5. El cuello de botella son los datos**, no el algoritmo: cambiar de Random Forest a CatBoost mejoró unas centésimas; resolver la confusión estudio–especie cambiaría las conclusiones.

7. Posibles errores detectados

Revisando a fondo los archivos aparecen problemas de tres tipos: **estadísticos** (pueden cambiar conclusiones), **de datos** y **de reporte/reproducibilidad**. Gravedad: Alta = puede cambiar un veredicto; Media = afecta la interpretación; Baja = forma o mantenimiento.

#	Gravedad	Problema	Evidencia en los archivos
1	Alta	Los valores p son el **mínimo posible** según el número de permutaciones, no una medida real de significancia.	Con 20 permutaciones el p mínimo es 1/21 = 0,048; con 30, 0,032. M01 con 10 permutaciones dio p = 0,091 y con 20 dio 0,048: el veredicto cambió solo por cambiar el número de permutaciones.
2	Alta	Sin corrección por **comparaciones múltiples** entre los 18 experimentos.	Seis veredictos “robusta/débil” dependen de p = 0,032–0,048, justo bajo 0,05. Con Bonferroni/BH y tan pocas permutaciones, ninguno sería significativo.
3	Alta	Umbrales de veredicto **al filo**: pequeñas variaciones cambian la etiqueta.	M05 ganancia 0,152 y M14 0,154 son “robustas” (umbral 0,15); M17b con 0,144 es “débil”. Sin intervalos de confianza no se pueden distinguir.
4	Alta	“Señal robusta” en M05 Familia es engañosa.	El acierto proviene casi solo de Rubiaceae (3 artículos); Orchidaceae y otras 5 familias tienen recall 0.
5	Alta	M11 (columna) marcado como “robusta” con color de éxito.	Es un efecto de plataforma, no química de la planta. Debería tener un veredicto propio (“diagnóstico de plataforma”).
6	Media	Sin control de plataforma en M01, M08, M09 y M17b.	La columna “control_plataforma” está vacía; la ganancia se calcula solo contra la línea base.
7	Media	Control de plataforma = 0,000 en M07.	Un control con exactitud exactamente 0 sugiere un fallo (clase no predicha, o partición vacía), no un rendimiento real.
8	Media	Métricas raras en M05: LightGBM con top-3 de 0,758 pero BA de 0,158.	Indica probable mal calibrado o desbalance extremo por partición; conviene revisar la matriz de confusión.
9	Media	Duplicación de filas en Dataset.csv.	317 797 filas repetidas por la unión con actividades biológicas; cualquier conteo que no deduplique sobre-pondera esas muestras.
10	Media	Lotes sin especie o sin identificaciones.	BAT0005/0006 (402 muestras, 872 673 filas) tienen especie “No especificado”; BAT0004–0006 y BAT0018 tienen 0 % identificado. ID_ARTICULO = 0 en lotes 3 y 4.
11	Media	Cambio de unidad de análisis entre 15-oct y 16-oct sin documentar.	866 perfiles × 337 variables pasaron a 53 filas × 812 variables; DBSCAN pasó de silhouette 0,75 a fallar. Los dos informes no son comparables.
12	Baja	Errores de formato y unidades.	Resumen del 21-oct muestra grupos como “46.000” (decimales de más). En el 15-oct, conteos reportados como porcentajes (387, 455, 490).
13	Baja	Resumen del 22-oct incompleto.	Faltan M17 y M18; la carpeta 22-oct no trae ejecuciones ni métricas que respalden los nuevos valores (solo la tabla y la gráfica).
14	Baja	Fechas y rutas inconsistentes.	La carpeta 2026-10-21 contiene ejecuciones del 22-oct; el informe cita “04_Resultados/” pero el README usa “03_Resultados/”. huellas.json usa rutas absolutas de Windows.
15	Baja	Archivos guardados como punteros Git LFS.	29 archivos (p. ej. resumen_ejecutivo.csv, resultados.csv, el .parquet) son punteros LFS; quien clone sin LFS no ve los datos.

8. Cómo podría mejorarlo

Ordenado de lo más rápido y barato a lo más costoso. Los números entre corchetes indican qué error de la sección 7 resuelve.

A. Cambios en el código (días)

- **Subir las permutaciones a ≥ 1 000** (al menos en los experimentos con veredicto positivo) y reportar p = (k+1)/(n+1). En los modelos lentos, usar LightGBM/logística para la permutación. [1]
- **Corregir por comparaciones múltiples** (Benjamini-Hochberg sobre los 18 experimentos) y mostrar p ajustado. [2]
- **Intervalos de confianza por bootstrap de artículos** (re-muestrear artículos completos 1 000 veces). Dar el veredicto según si el intervalo de la ganancia excluye 0 y 0,15, no por un umbral fijo. [3]
- **Repetir la validación cruzada con varias semillas** (p. ej. 5 × 5 particiones) para ver cuánto varía el resultado.
- **Reportar recall por clase** y un veredicto “dominado por una clase” cuando > 50 % del acierto venga de una sola. [4]
- **Nuevo veredicto “diagnóstico de plataforma”** para M11 y similares, con color neutro. [5]
- **Añadir control de plataforma** a M01, M08–M10 y M17b (p. ej. modelo solo con masa y artículo de origen). [6]
- **Pruebas automáticas** que fallen si un control da 0,000 exacto, si faltan experimentos en el resumen, o si un dataset tiene filas duplicadas. [7, 9, 13]
- **Deduplicar**: separar la tabla de actividades de la tabla química y unirlas solo cuando haga falta. [9]
- **Formato y rutas**: redondear enteros, usar rutas relativas en huellas.json, unificar nombres de carpetas y fechar cada carpeta con la fecha real de ejecución. Documentar si se usa Git LFS. [12, 14, 15]

B. Mejoras de análisis (semanas)

- **Validación “dejar una plataforma fuera”** (además de por artículo): entrenar con columnas Agilent y probar con Waters, etc.
- **Corrección de efecto lote** (ComBat, o modelos mixtos con artículo como efecto aleatorio) antes de buscar señal taxonómica.
- **Restringir a la biblioteca común**: comparar perfiles solo con metabolitos que todos los laboratorios podían detectar, para que “no detectado” signifique “ausente” y no “no estaba en mi biblioteca”.
- **Usar el 74 % de señales no identificadas**: con m/z y masa exacta se pueden asignar fórmulas candidatas y luego aplicar M08/M09 para darles clase química. Esto multiplicaría los datos útiles.
- **Aprovechar M08/M09 como herramienta**: publicar un pequeño anotador “fórmula → superclase/clase” con su probabilidad.
- **Aprendizaje PU** para actividades biológicas (solo hay positivos de literatura), en lugar de tratar la ausencia como negativo.
- **Recuperar el mapeo pozo-especie** de BAT0005/0006 o excluirlos explícitamente. [10]

C. Mejoras de datos (meses) — las que más cambiarían las conclusiones

- **Más orquídeas medidas con un mismo protocolo**: idealmente ≥ 5 géneros de Orchidaceae y especies control de otras familias, en el mismo equipo y la misma columna. Es la única forma de responder la pregunta central del proyecto.
- **Muestras puente**: una misma muestra de referencia medida en varios laboratorios para calibrar y separar laboratorio de planta.
- **Espectros MS/MS e índices de retención**: permiten identificar compuestos desconocidos y comparar entre lotes.

- **Ensayos de actividad propios con controles negativos** y unidades homogéneas, para poder hacer regresión de potencia.
- **Verificar los estilbenos** (dihidroresveratrol, isorhapontigenina, pterostilbeno) en *Gastrodia*, *Dendrobium* y otras orquídeas con patrones puros: es la hipótesis más concreta y barata de confirmar.

Prioridad recomendada. (1) Permutaciones ≥ 1 000 + corrección BH + intervalos por bootstrap, porque pueden cambiar los veredictos actuales; (2) validación por plataforma y biblioteca común; (3) diseñar el siguiente muestreo con orquídeas bajo un protocolo único.

Fuentes: 00_Informes/2026-10-15 (PDF y 03_Resultados/Global), 2026-10-16 (PDF, Global, Base), 2026-10-21 (auditoria_datos/oficial, informes, ejecuciones/*/informe.md, 05_Documentacion) y 2026-10-22 (Global/resumen_ejecutivo.md). Las figuras de este informe se generaron a partir de esas cifras.